

I. Question 6.2.a use a CUSUM approach to identify when unofficial summer ends

- Using July through October daily-high-temperature data for Atlanta for 1996 through 2015, use a CUSUM approach to identify when unofficial summer ends (i.e., when the weather starts cooling off) each year. You can get the data that you need from the file `temps.txt` or online, for example at <http://www.iweather.net/atlanta-weather-records> or <https://www.wunderground.com/history/airport/KFTY/2015/7/1/CustomHistory.html>. You can use R if you'd like, but it's straightforward enough that an Excel spreadsheet can easily do the job too.

Results:

Step#1 : Identify best values of C and T

How : I used excel and obtained average temperature for all the days across 20 years to identify the best suited C and T values and also to validate the results in R. As part of analysis, I have selected C=5 and threshold as 82

|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|--|

Step#2: Ingest data


```
> ###Question 6.2###
>
> ###Input : July through October daily-high-temperature data for Atlanta for 1996 through 2015,\
> #####ASK: use a CUSUM approach to identify when unofficial summer ends
> #####(i.e., when the weather starts cooling off) each year.
> #####OPTIONS: You can use R if you'd like, OR Excel spreadsheet
>
>
> #####CLEAR#####
> rm(list = ls())
>
> #####LIBRARY#####
>
>
> #####INGEST FILE#####
>
> data<- read.table("6_2temps.txt",header=TRUE,stringsAsFactors = FALSE,sep="\t")
> #summary(data)
> length(data) # no of columns
[1] 21
>
> head(data,10)
      DAY X1996 X1997 X1998 X1999 X2000 X2001 X2002 X2003 X2004 X2005 X2006
1  1-Jul   98    86    91    84    89    84    90    73    82    91    93
2  2-Jul   97    90    88    82    91    87    90    81    81    89    93
3  3-Jul   97    93    91    87    93    87    87    87    86    86    93
4  4-Jul   90    91    91    88    95    84    89    86    88    86    91
5  5-Jul   89    84    91    90    96    86    93    80    90    89    90
6  6-Jul   93    84    89    91    96    87    93    84    90    82    81
7  7-Jul   93    75    93    82    96    87    89    87    89    76    80
8  8-Jul   91    87    95    86    91    89    89    90    87    88    82
9  9-Jul   93    84    95    87    96    91    90    89    88    89    84
10 10-Jul   93    87    91    87    99    87    91    84    89    78    84
      X2007 X2008 X2009 X2010 X2011 X2012 X2013 X2014 X2015
1     95    85    95    87    92   105    82    90    85
2     85    87    90    84    94    93    85    93    87
3     82    91    89    83    95    99    76    87    79
4     86    90    91    85    92    98    77    84    85
5     88    88    80    88    90   100    83    86    84
6     87    82    87    89    90    98    83    87    84
7     82    88    86    94    94    93    79    89    90
8     82    90    82    97    94    95    88    90    90
9     89    89    84    96    91    97    88    90    91
10    86    87    84    90    92    95    87    87    93
```

Step#3: Obtain average of all days and show averages by day

```
> #####ggplot(data)#####
> date_avgs <- rowMeans(data[c(2:length(data))], dims=1, na.rm=T)
> cbind(data[1],date_avgs)
```

	DAY	date_avgs
1	1-Jul	88.85
2	2-Jul	88.35
3	3-Jul	88.40
4	4-Jul	88.35
5	5-Jul	88.25
6	6-Jul	87.85
7	7-Jul	87.10
8	8-Jul	89.15
9	9-Jul	90.05
10	10-Jul	88.55
11	11-Jul	87.95
12	12-Jul	88.15
13	13-Jul	87.20
14	14-Jul	88.20
15	15-Jul	87.00
16	16-Jul	88.10
17	17-Jul	89.20
18	18-Jul	89.25
19	19-Jul	90.40
20	20-Jul	89.40
21	21-Jul	89.95
22	22-Jul	89.45
23	23-Jul	89.05
24	24-Jul	89.10
25	25-Jul	88.00
26	26-Jul	89.50
27	27-Jul	89.55
28	28-Jul	89.95
29	29-Jul	89.25
30	30-Jul	89.55
31	31-Jul	88.15
32	1-Aug	88.55
33	2-Aug	88.65
34	3-Aug	89.55
35	4-Aug	90.30
36	5-Aug	91.15
37	6-Aug	89.40
38	7-Aug	88.95
39	8-Aug	88.75
40	9-Aug	89.00
41	10-Aug	89.25

Step#4 setup C and Threshold . calculate CUSUM



```
> #####CHECK NUMBER OF ROWS#####
> n <- length(date_avgs) # 123 data points
> ntest <- nrow(data[1])
>
> x_t <- date_avgs
>
> mean_x_t <- mean(x_t)
>
> mean_x_t
[1] 83.33902
>
> # set up based on analysis in excel
> C <- 5
>
> #Threshold for Temp drop set to 82.
>
> #plot average
> #plot(date_avgs,ylim=c(50,110),xlab="date",ylab="Avg",type="l")
>
> # as we are seeing decrease in temperature, we calculate mean - data
>
> mean_data <- mean_x_t-date_avgs
>
> # subtract C from the difference score
> s_t <- mean_data - C
>
> s_t
[1] -10.5109756 -10.0109756 -10.0609756 -10.0109756 -9.9109756 -9.5109756 -8.7609756 -10.8109756
[9] -11.7109756 -10.2109756 -9.6109756 -9.8109756 -8.8609756 -9.8609756 -8.6609756 -9.7609756
[17] -10.8609756 -10.9109756 -12.0609756 -11.0609756 -11.6109756 -11.1109756 -10.7109756 -10.7609756
[25] -9.6609756 -11.1609756 -11.2109756 -11.6109756 -10.9109756 -11.2109756 -9.8109756 -10.2109756
[33] -10.3109756 -11.2109756 -11.9609756 -12.8109756 -11.0609756 -10.6109756 -10.4109756 -10.6609756
[41] -10.9109756 -10.8609756 -9.5609756 -9.7609756 -9.9609756 -9.6609756 -10.4609756 -10.7109756
[49] -11.8109756 -11.9609756 -10.9609756 -10.7609756 -11.0609756 -10.0609756 -9.5109756 -8.1609756
[57] -10.1109756 -9.2609756 -8.8109756 -9.9609756 -7.4609756 -7.5609756 -6.9109756 -6.9109756
[65] -7.5609756 -7.4609756 -7.8609756 -6.2609756 -6.4109756 -6.9109756 -6.7109756 -6.9109756
[73] -7.2109756 -6.9609756 -4.7609756 -5.3109756 -5.3609756 -3.9109756 -3.5109756 -3.3609756
```

```

<
> #precusum <- 0 * s_t
> cusum <- append(0, 0)
> cusum
[1] 0 0
> cusum[1]
[1] 0
>
> for (i in 1:length(s_t))
+ {
+   ifelse(cusum[i] + s_t[i-1] > 0, cusum[i+1] <- cusum[i] + s_t[i-1], cusum[i+1] <- 0)
+ }
>
> cusum
[1] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
[10] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
[19] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
[28] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
[37] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
[46] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
[55] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
[64] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
[73] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
[82] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
[91] 0.000000 0.000000 1.989024 3.328049 4.567073 5.956098 6.595122 7.084146 7.223171
[100] 9.212195 11.951220 15.490244 19.579268 22.768293 25.257317 27.796341 30.685366 34.824390
[109] 40.263415 45.952439 51.191463 57.630488 64.919512 72.008537 76.247561 82.236585 90.925610
[118] 100.414634 109.403659 116.342683 125.781707 135.520732 144.509756 151.798780
> length(cusum[-1])
[1] 123
> cbind(data[1],cusum[-1])
      DAY  cusum[-1]
1  1-Jul  0.000000
2  2-Jul  0.000000
3  3-Jul  0.000000
4  4-Jul  0.000000
5  5-Jul  0.000000

```


Step#5 : find the day when the threshold has reached

```

> cusum[1]
[1] 0
>
> for (i in 1:length(s_t))
+ {
+   ifelse(cusum[i] + s_t[i-1] > 0, cusum[i+1] <- cusum[i] + s_t[i-1], cusum[i+1] <- 0)
+ }
>
> cusum
  [1] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
 [10] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
 [19] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
 [28] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
 [37] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
 [46] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
 [55] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
 [64] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
 [73] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
 [82] 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000 0.000000
 [91] 0.000000 0.000000 1.989024 3.328049 4.567073 5.956098 6.595122 7.084146 7.223171
[100] 9.212195 11.951220 15.490244 19.579268 22.768293 25.257317 27.796341 30.685366 34.824390
[109] 40.263415 45.952439 51.191463 57.630488 64.919512 72.008537 76.247561 82.236585 90.925610
[118] 100.414634 109.403659 116.342683 125.781707 135.520732 144.509756 151.798780
> length(cusum[-1])
[1] 123
> cbind(data[1],cusum[-1])
      DAY  cusum[-1]
1  1-Jul  0.000000
2  2-Jul  0.000000
3  3-Jul  0.000000
4  4-Jul  0.000000
5  5-Jul  0.000000
6  6-Jul  0.000000
-  - - -  - - - - -
>
> which(cusum >= 82)
[1] 116 117 118 119 120 121 122 123 124
>
> data[116, 1]
[1] "24-Oct"

```

The date returned for unofficial summer end is 10/24



2. **Question 6.2.b** Use a CUSUM approach to make a judgment of whether Atlanta's summer climate has gotten warmer in that time (and if so, when).


Step#1 Understand data

Yearly datasets were hard to visualize. Hence I categorized the datasets into 5 year buckets and obtained mean for each bucket

```
>
> #####HAS ATLANTA CLIMATE GOT WARMER BY YEARS?#####
> # categorize the 20 years data into 5 buckets of 5 years
>
> yearset_1 <-data[2:6]
> head(yearset_1)
  X1996 X1997 X1998 X1999 X2000
1     98     86     91     84     89
2     97     90     88     82     91
3     97     93     91     87     93
4     90     91     91     88     95
5     89     84     91     90     96
6     93     84     89     91     96
> yearset_2 <-data[7:11]
> head(yearset_2)
  X2001 X2002 X2003 X2004 X2005
1     84     90     73     82     91
2     87     90     81     81     89
3     87     87     87     86     86
4     84     89     86     88     86
5     86     93     80     90     89
6     87     93     84     90     82
> yearset_3 <-data[12:16]
> head(yearset_3)
  X2006 X2007 X2008 X2009 X2010
1     93     95     85     95     87
2     93     85     87     90     84
3     93     82     91     89     83
4     91     86     90     91     85
5     90     88     88     80     88
6     81     87     82     87     89
> yearset_4 <-data[17:length(data)]
> head(yearset_4)
  X2011 X2012 X2013 X2014 X2015
1     92    105     82     90     85
2     94     93     85     93     87
3     95     99     76     87     79
4     92     98     77     84     85
5     90    100     83     86     84
6     90     98     83     87     84
```



```
<
> yearset1_mu= rowMeans(yearset_1, dims=1, na.rm=T)
> yearset1_mu
[1] 89.6 89.6 92.2 91.0 90.0 90.6 87.8 90.0 91.0 91.4 88.6 87.0 86.2 88.8 87.6 89.6 89.6 91.8 93.6 93.8
[21] 90.8 91.0 89.8 89.4 85.0 87.2 86.8 88.4 90.0 90.6 86.0 86.8 86.0 85.6 88.6 90.6 89.0 89.6 86.8 86.4
[41] 88.2 89.4 89.0 88.8 88.0 89.2 91.4 92.2 93.2 93.6 88.4 86.8 86.8 87.4 86.6 86.4 89.0 88.2 89.6 91.0
[61] 89.4 86.4 84.4 84.0 84.6 87.0 87.2 84.4 84.4 86.4 82.2 82.2 84.0 86.2 85.4 85.2 86.0 82.8 82.6 80.6
[81] 82.6 82.2 81.0 76.8 80.8 81.8 79.6 77.6 75.8 75.6 74.8 74.2 75.4 75.4 80.4 76.4 76.8 72.6 72.6 71.4
[101] 69.8 72.6 74.6 73.8 74.0 74.4 74.6 74.4 77.0 71.8 70.6 69.2 72.2 71.6 65.4 68.2 73.0 73.8 72.8 73.6
[121] 74.2 76.4 74.6
> yearset2_mu= rowMeans(yearset_2, dims=1, na.rm=T)
> yearset3_mu= rowMeans(yearset_3, dims=1, na.rm=T)
> yearset4_mu= rowMeans(yearset_4, dims=1, na.rm=T)
>
>
> Day=data[1]
> #Day
>
> #plot(yearset1_mu,type="l",ylab="Avg. Temperature")
> plot(yearset1_mu, type="o", col="green", pch="l", lty=1, ylim=c(60,110) )
>
> ### Use RED for 2nd 5 years.
> #points(yearset2_mu, col="red", pch="*")
> lines(yearset2_mu, col="red",lty=1)
>
> ### Use GREEN for 3nd 5 years.
> lines(yearset3_mu, col="blue",lty=1)
>
> ### Use GREEN for 4th 5 years.
> lines(yearset4_mu, col="black",lty=1)
>
>
>
> ###add legend
> legend(1,108,legend=c("y1","y2","y3","y4"), col=c("green","red","blue","black"),
+       pch=c("o","*","+"),lty=c(1,1,1), ncol=1)
```



Year#1 category :1996 -2000
 Year#2 category :2001 -2005
 Year#3 category :2006-2010
 Year#4 category :2011 -2015

Visually it looks like last 2 set (9 years average) is showing spikes

```
> # average of all days in each year set
>
> yearset1_overall_mu=mean(yearset1_mu)
> yearset2_overall_mu=mean(yearset2_mu)
> yearset3_overall_mu=mean(yearset3_mu)
> yearset4_overall_mu=mean(yearset4_mu)
>
>
> rbind(yearset1_overall_mu,yearset2_overall_mu,yearset3_overall_mu,yearset4_overall_mu)
      [,1]
yearset1_overall_mu 83.40813
yearset2_overall_mu 82.34797
yearset3_overall_mu 83.83252
yearset4_overall_mu 83.76748
.
```

Overall Avg. temperature of the year as well shows increase in the last 2 data sets.

- I developed CUSUM increase approach in spreadsheet with the below parameters and noticed the threshold 4 reaches in **2011**.

	A	B	C	D	E	F	G	H	I
1					C=0.65	T=4			
2	year	yearly Avg. Temp	Mean	x(t)-mean	C	x(t)-mean-c	s(t-1)+(x(t)-mean-c)		
3	1996	83.71544715	83.33902	0.376422764	0.65	-0.273577236	0		
4	1997	81.67479675	83.33902	-1.664227642	0.65	-2.314227642	0		
5	1998	84.2601626	83.33902	0.921138211	0.65	0.271138211	0.271138211		
6	1999	83.35772358	83.33902	0.018699187	0.65	-0.631300813	0		
7	2000	84.03252033	83.33902	0.693495935	0.65	0.043495935	0.043495935		
8	2001	81.55284553	83.33902	-1.786178862	0.65	-2.436178862	0		
9	2002	83.58536585	83.33902	0.246341463	0.65	-0.403658537	0		
10	2003	81.4796748	83.33902	-1.859349593	0.65	-2.509349593	0		
11	2004	81.76422764	83.33902	-1.574796748	0.65	-2.224796748	0		
12	2005	83.35772358	83.33902	0.018699187	0.65	-0.631300813	0		
13	2006	83.04878049	83.33902	-0.290243902	0.65	-0.940243902	0		
14	2007	85.39837398	83.33902	2.059349593	0.65	1.409349593	1.409349593		
15	2008	82.51219512	83.33902	-0.826829268	0.65	-1.476829268	0		
16	2009	80.99186992	83.33902	-2.347154472	0.65	-2.997154472	0		
17	2010	87.21138211	83.33902	3.872357724	0.65	3.222357724	3.222357724		
18	2011	85.27642276	83.33902	1.937398374	0.65	1.287398374	4.509756098	<=Threshold=4	
19	2012	84.6504065	83.33902	1.311382114	0.65	0.661382114	5.171138211		
20	2013	81.66666667	83.33902	-1.672357724	0.65	-2.322357724	2.848780488		
21	2014	83.94308943	83.33902	0.604065041	0.65	-0.045934959	2.802845528		
22	2015	83.30081301	83.33902	-0.038211382	0.65	-0.688211382	2.114634146		

Question 5.1

Input: uscrime.txt


Objective: test to see whether there are any outliers in the last column (number of crimes per 100,000 people). Use the `grubbs.test` function in the `outliers` package in R.

A. Step#1: Visualize outliers

```
> ###Question 5.1
>
> ###Input : http://www.statsci.org/data/general/uscrime.txt
>
> ####ASK: test to see whether there are any outliers in the last column (# of crimes per 100k)
>
> ####OPTIONS: Use the grubbs.test function in the outliers package in R.
>
>
> #####CLEAR#####
> rm(list = ls())
> set.seed(100)
>
> #####LIBRARY#####
> #install.packages("outliers")
> library(outliers)
> data<- read.table("5_luscrime.txt",header=TRUE,stringsAsFactors = FALSE,sep="\t")
> head(data,10)
```

	M	So	Ed	Pol	Po2	LF	M.F	Pop	NW	U1	U2	Wealth	Ineq	Prob	Time	Crime
1	15.1	1	9.1	5.8	5.6	0.510	95.0	33	30.1	0.108	4.1	3940	26.1	0.084602	26.2011	791
2	14.3	0	11.3	10.3	9.5	0.583	101.2	13	10.2	0.096	3.6	5570	19.4	0.029599	25.2999	1635
3	14.2	1	8.9	4.5	4.4	0.533	96.9	18	21.9	0.094	3.3	3180	25.0	0.083401	24.3006	578
4	13.6	0	12.1	14.9	14.1	0.577	99.4	157	8.0	0.102	3.9	6730	16.7	0.015801	29.9012	1969
5	14.1	0	12.1	10.9	10.1	0.591	98.5	18	3.0	0.091	2.0	5780	17.4	0.041399	21.2998	1234
6	12.1	0	11.0	11.8	11.5	0.547	96.4	25	4.4	0.084	2.9	6890	12.6	0.034201	20.9995	682
7	12.7	1	11.1	8.2	7.9	0.519	98.2	4	13.9	0.097	3.8	6200	16.8	0.042100	20.6993	963
8	13.1	1	10.9	11.5	10.9	0.542	96.9	50	17.9	0.079	3.5	4720	20.6	0.040099	24.5988	1555
9	15.7	1	9.0	6.5	6.2	0.553	95.5	39	28.6	0.081	2.8	4210	23.9	0.071697	29.4001	856
10	14.0	0	11.8	7.1	6.8	0.632	102.9	7	1.5	0.100	2.4	5260	17.4	0.044498	19.5994	705

```
>
> #Scatterplot
> plot(data$Crime)
```



B. Results : There seems to be highest outlier point

```
>
> # Grubbs test allows to detect whether the highest or lowest value in a dataset is an outlier.
> ###DETECT HIGH OUTLIER###
> Outhigh <- grubbs.test(data$Crime)
> Outhigh

      Grubbs test for one outlier

data:  data$Crime
G = 2.81287, U = 0.82426, p-value = 0.07887
alternative hypothesis: highest value 1993 is an outlier

>
> ## if the p-value <= ( $\alpha=0.05$ ), then the null hypothesis is rejected
> ## THEN we will conclude that the lowest/highest value is an outlier.
>
> ### p-value >= 0.05, null hypothesis is not rejected,
> ### we do not reject the hypothesis that the lowest/highest value is not an outlier.
>
>
> ###DETECT LOW OUTLIER
> Outlow <- grubbs.test(data$Crime, opposite = TRUE)
> Outlow

      Grubbs test for one outlier

data:  data$Crime
G = 1.45589, U = 0.95292, p-value = 1
alternative hypothesis: lowest value 342 is an outlier

>
> dataY=data$Crime
> which(dataY== 1993)
[1] 26
> which(dataY== 342)
[1] 27
>
```

Row#26 holds the highest Outlier point and Row#27 is the lowest Outlier point

```
> head(data,27)
  M So  Ed  Pol  Po2  LF  M.F Pop  NW  U1  U2 Wealth Ineq  Prob  Time Crime
1 15.1 1  9.1  5.8  5.6 0.510 95.0 33 30.1 0.108 4.1  3940 26.1 0.084602 26.2011  791
2 14.3 0 11.3 10.3  9.5 0.583 101.2 13 10.2 0.096 3.6  5570 19.4 0.029599 25.2999 1635
3 14.2 1  8.9  4.5  4.4 0.533 96.9 18 21.9 0.094 3.3  3180 25.0 0.083401 24.3006  578
4 13.6 0 12.1 14.9 14.1 0.577 99.4 157  8.0 0.102 3.9  6730 16.7 0.015801 29.9012 1969
5 14.1 0 12.1 10.9 10.1 0.591 98.5 18  3.0 0.091 2.0  5780 17.4 0.041399 21.2998 1234
6 12.1 0 11.0 11.8 11.5 0.547 96.4 25  4.4 0.084 2.9  6890 12.6 0.034201 20.9995  682
7 12.7 1 11.1  8.2  7.9 0.519 98.2  4 13.9 0.097 3.8  6200 16.8 0.042100 20.6993  963
8 13.1 1 10.9 11.5 10.9 0.542 96.9 50 17.9 0.079 3.5  4720 20.6 0.040099 24.5988 1555
9 15.7 1  9.0  6.5  6.2 0.553 95.5 39 28.6 0.081 2.8  4210 23.9 0.071697 29.4001  856
10 14.0 0 11.8  7.1  6.8 0.632 102.9  7  1.5 0.100 2.4  5260 17.4 0.044498 19.5994  705
11 12.4 0 10.5 12.1 11.6 0.580 96.6 101 10.6 0.077 3.5  6570 17.0 0.016201 41.6000 1674
12 13.4 0 10.8  7.5  7.1 0.595 97.2 47  5.9 0.083 3.1  5800 17.2 0.031201 34.2984  849
13 12.8 0 11.3  6.7  6.0 0.624 97.2 28  1.0 0.077 2.5  5070 20.6 0.045302 36.2993  511
14 13.5 0 11.7  6.2  6.1 0.595 98.6 22  4.6 0.077 2.7  5290 19.0 0.053200 21.5010  664
15 15.2 1  8.7  5.7  5.3 0.530 98.6 30  7.2 0.092 4.3  4050 26.4 0.069100 22.7008  798
16 14.2 1  8.8  8.1  7.7 0.497 95.6 33 32.1 0.116 4.7  4270 24.7 0.052099 26.0991  946
17 14.3 0 11.0  6.6  6.3 0.537 97.7 10  0.6 0.114 3.5  4870 16.6 0.076299 19.1002  539
18 13.5 1 10.4 12.3 11.5 0.537 97.8 31 17.0 0.089 3.4  6310 16.5 0.119804 18.1996  929
19 13.0 0 11.6 12.8 12.8 0.536 93.4 51  2.4 0.078 3.4  6270 13.5 0.019099 24.9008  750
20 12.5 0 10.8 11.3 10.5 0.567 98.5 78  9.4 0.130 5.8  6260 16.6 0.034801 26.4010 1225
21 12.6 0 10.8  7.4  6.7 0.602 98.4 34  1.2 0.102 3.3  5570 19.5 0.022800 37.5998  742
22 15.7 1  8.9  4.7  4.4 0.512 96.2 22 42.3 0.097 3.4  2880 27.6 0.089502 37.0994  439
23 13.2 0  9.6  8.7  8.3 0.564 95.3 43  9.2 0.083 3.2  5130 22.7 0.030700 25.1989 1216
24 13.1 0 11.6  7.8  7.3 0.574 103.8  7  3.6 0.142 4.2  5400 17.6 0.041598 17.6000  968
25 13.0 0 11.6  6.3  5.7 0.641 98.4 14  2.6 0.070 2.1  4860 19.6 0.069197 21.9003  523
26 13.1 0 12.1 16.0 14.3 0.631 107.1  3  7.7 0.102 4.1  6740 15.2 0.041698 22.1005 1993
27 13.5 0 10.9  6.9  7.1 0.540 96.5  6  0.4 0.080 2.2  5640 13.9 0.036099 28.4999  342
>
```

C. View sorted results


```
> newdata <- data[order(Crime),]
> newdata
  M So  Ed  Po1  Po2  LF  M.F Pop  NW  U1  U2 Wealth Ineq  Prob  Time Crime
27 13.5 0 10.9 6.9 7.1 0.540 96.5 6 0.4 0.080 2.2 5640 13.9 0.036099 28.4999 342
31 14.0 0 9.3 5.5 5.4 0.535 104.5 6 2.0 0.135 4.0 4530 20.0 0.041999 21.7998 373
22 15.7 1 8.9 4.7 4.4 0.512 96.2 22 42.3 0.097 3.4 2880 27.6 0.089502 37.0994 439
45 13.9 1 8.8 4.6 4.1 0.480 96.8 19 4.9 0.135 5.3 4570 24.9 0.056202 32.5996 455
46 12.6 0 10.4 10.6 9.7 0.599 98.9 40 2.4 0.078 2.5 5930 17.1 0.046598 16.6999 508
13 12.8 0 11.3 6.7 6.0 0.624 97.2 28 1.0 0.077 2.5 5070 20.6 0.045302 36.2993 511
25 13.0 0 11.6 6.3 5.7 0.641 98.4 14 2.6 0.070 2.1 4860 19.6 0.069197 21.9003 523
17 14.3 0 11.0 6.6 6.3 0.537 97.7 10 0.6 0.114 3.5 4870 16.6 0.076299 19.1002 539
42 14.1 0 10.9 5.6 5.4 0.523 96.8 4 0.2 0.107 3.7 4890 17.0 0.088904 12.1996 542
38 13.3 0 10.4 5.1 4.7 0.599 102.4 7 4.0 0.099 2.7 4250 22.5 0.053998 16.6999 566
3 14.2 1 8.9 4.5 4.4 0.533 96.9 18 21.9 0.094 3.3 3180 25.0 0.083401 24.3006 578
35 12.3 0 10.2 9.7 8.7 0.526 94.8 113 7.6 0.124 5.0 5720 15.8 0.020700 37.4011 653
14 13.5 0 11.7 6.2 6.1 0.595 98.6 22 4.6 0.077 2.7 5290 19.0 0.053200 21.5010 664
6 12.1 0 11.0 11.8 11.5 0.547 96.4 25 4.4 0.084 2.9 6890 12.6 0.034201 20.9995 682
30 16.6 1 8.9 5.8 5.4 0.521 97.3 46 25.4 0.072 2.6 3960 23.7 0.075298 28.3011 696
10 14.0 0 11.8 7.1 6.8 0.632 102.9 7 1.5 0.100 2.4 5260 17.4 0.044498 19.5994 705
21 12.6 0 10.8 7.4 6.7 0.602 98.4 34 1.2 0.102 3.3 5570 19.5 0.022800 37.5998 742
19 13.0 0 11.6 12.8 12.8 0.536 93.4 51 2.4 0.078 3.4 6270 13.5 0.019099 24.9008 750
32 12.5 0 10.9 9.0 8.1 0.586 96.4 97 8.2 0.105 4.3 6170 16.3 0.042698 30.9014 754
1 15.1 1 9.1 5.8 5.6 0.510 95.0 33 30.1 0.108 4.1 3940 26.1 0.084602 26.2011 791
15 15.2 1 8.7 5.7 5.3 0.530 98.6 30 7.2 0.092 4.3 4050 26.4 0.069100 22.7008 798
43 16.2 1 9.9 7.5 7.0 0.522 99.6 40 20.8 0.073 2.7 4960 22.4 0.054902 31.9989 823
39 14.9 1 8.8 6.1 5.4 0.515 95.3 36 16.5 0.086 3.5 3950 25.1 0.047099 27.3004 826
37 17.7 1 8.7 5.8 5.6 0.638 97.4 24 34.9 0.076 2.8 3820 25.4 0.045198 31.6995 831
12 13.4 0 10.8 7.5 7.1 0.595 97.2 47 5.9 0.083 3.1 5800 17.2 0.031201 34.2984 849
47 13.0 0 12.1 9.0 9.1 0.623 104.9 3 2.2 0.113 4.0 5880 16.0 0.052802 16.0997 849
9 15.7 1 9.0 6.5 6.2 0.553 95.5 39 28.6 0.081 2.8 4210 23.9 0.071697 29.4001 856
41 14.8 0 12.2 7.2 6.6 0.601 99.8 9 1.9 0.084 2.0 5900 14.4 0.025100 30.0001 880
34 12.6 0 11.8 9.7 9.7 0.542 99.0 18 2.1 0.102 3.5 5890 16.6 0.040799 21.6997 923
18 13.5 1 10.4 12.3 11.5 0.537 97.8 31 17.0 0.089 3.4 6310 16.5 0.119804 18.1996 929
16 14.2 1 8.8 8.1 7.7 0.497 95.6 33 32.1 0.116 4.7 4270 24.7 0.052099 26.0991 946
7 12.7 1 11.1 8.2 7.9 0.519 98.2 4 13.9 0.097 3.8 6200 16.8 0.042100 20.6993 963
24 13.1 0 11.6 7.8 7.3 0.574 103.8 7 3.6 0.142 4.2 5400 17.6 0.041598 17.6000 968
44 13.6 0 12.1 9.5 9.6 0.574 101.2 29 3.6 0.111 3.7 6220 16.2 0.028100 30.0001 1030
29 11.9 0 10.7 16.6 15.7 0.521 93.8 168 8.9 0.092 3.6 6370 15.4 0.023400 36.7009 1043
33 14.7 1 10.4 6.3 6.4 0.560 97.2 23 9.5 0.076 2.4 4620 23.3 0.049499 25.5005 1072
40 14.5 1 10.4 8.2 7.4 0.560 98.1 96 12.6 0.088 3.1 4880 22.8 0.038801 29.3004 1151
23 13.2 0 9.6 8.7 8.3 0.564 95.3 43 9.2 0.083 3.2 5130 22.7 0.030700 25.1989 1216
28 15.2 0 11.2 8.2 7.6 0.571 101.8 10 7.9 0.103 2.8 5370 21.5 0.038201 25.8006 1216
20 12.5 0 10.8 11.3 10.5 0.567 98.5 78 9.4 0.130 5.8 6260 16.6 0.034801 26.4010 1225
5 14.1 0 12.1 10.9 10.1 0.591 98.5 18 3.0 0.091 2.0 5780 17.4 0.041399 21.2998 1234
36 15.0 0 10.0 10.9 9.8 0.531 96.4 9 2.4 0.087 3.8 5590 15.3 0.006900 44.0004 1272
8 13.1 1 10.9 11.5 10.9 0.542 96.9 50 17.9 0.079 3.5 4720 20.6 0.040099 24.5988 1555
2 14.3 0 11.3 10.3 9.5 0.583 101.2 13 10.2 0.096 3.6 5570 19.4 0.029599 25.2999 1635
11 12.4 0 10.5 12.1 11.6 0.580 96.6 101 10.6 0.077 3.5 6570 17.0 0.016201 41.6000 1674
4 13.6 0 12.1 14.9 14.1 0.577 99.4 157 8.0 0.102 3.9 6730 16.7 0.015801 29.9012 1969
26 13.1 0 12.1 16.0 14.3 0.631 107.1 3 7.7 0.102 4.1 6740 15.2 0.041698 22.1005 1993
> D|
```

D. Results: the highest outlier is 1993 with the next closet point in the scatterplot noted by 1969

Question 6.1 Describe a situation or problem from your job, everyday life, current events, etc., for which a Change Detection model would be appropriate. Applying the CUSUM technique, how would you choose the critical value and the threshold?

While listening to the tutorial for CUSUM process, the very first situation that I could relate is with an ongoing initiative at work for COVID Vaccination. To encourage vaccination with our workforce, our organization has introduced a random drawing every couple of week that will select 10 winners and award them \$2000. To enroll in this program, we had to register our vaccination details to HR for management to understand if there is any positive impact in motivating employees towards vaccination.

For example, we have 10,000 employees and before this initiative, we have less 1% employee vaccination records that organization holds. Organization was able to obtain more visibility on vaccination entries after this initiative. We can use historical data along with the time series data collected after the initiative. Using CUSUM, we can detect the increase in employee vaccination trending over time.

Selecting T & C:

Considering goal of the organization as 50% for employee vaccination, I will set this as threshold “T”

Coming to C value, between tradeoff on False positive vs. Late detection, I will choose late detection and hence I will start with $C=0$ and choose a BIGGER value for “C” to prefer a less sensitive CUSUM program.